Informe gerencial - Etapa 3
Segmentación de clientes con K-Means

Procesamiento de lenguaje natural / Machine learning - Universidad de Cundinamarca, Extensión Facatativá
Integrantes: [COMPLETAR] - Docente: Ing. Freddy Martínez - Noviembre de 2026

1. Resumen ejecutivo

Se segmentaron 60 clientes ficticios de una tienda según tres variables de los últimos 90 días: número de compras, gasto en pesos colombianos y días desde la última compra. Se usó K-Means (aprendizaje no supervisado, sin etiquetas correctas) sobre datos estandarizados. Con K = 3 se obtienen tres grupos de tamaño parejo (21, 20 y 19 clientes) y una silueta de 0,611, que indica grupos bien separados en estos datos sintéticos. A cada grupo se le propone una campaña distinta; esas campañas son reglas comerciales humanas, no resultados del modelo.

2. Metodología

Se cargó el archivo clientes_segmentacion.csv y se verificaron columnas, identificadores únicos y valores válidos. El identificador no se usa para entrenar. Las tres variables se estandarizaron con StandardScaler para que el gasto, que está en millones, no domine las distancias. Se ajustó KMeans con semilla 42 y n_init = 10, y se calculó la silueta (de -1 a 1; no es un porcentaje de aciertos). K = 3 fue una decisión de la práctica, no un valor óptimo demostrado, y se comparó con K = 2 como mini reto.

3. Resultados con K = 3

Grupo	Clientes	Compras (prom.)	Gasto prom. (COP)	Días sin comprar (prom.)	Campaña propuesta
0	21	7,4	707.905	24,9	Recompra: probar una oferta para la siguiente compra
1	20	2,2	136.250	65,2	Reactivación: mensaje de regreso con un incentivo
2	19	16,6	2.124.684	7,5	Fidelización: beneficios por compras repetidas

Tabla 1. Perfil promedio de cada grupo. Reglas didácticas: reactivar si promedia 45 días o más sin comprar; fidelizar si promedia 10 compras o más; recompra para los demás.

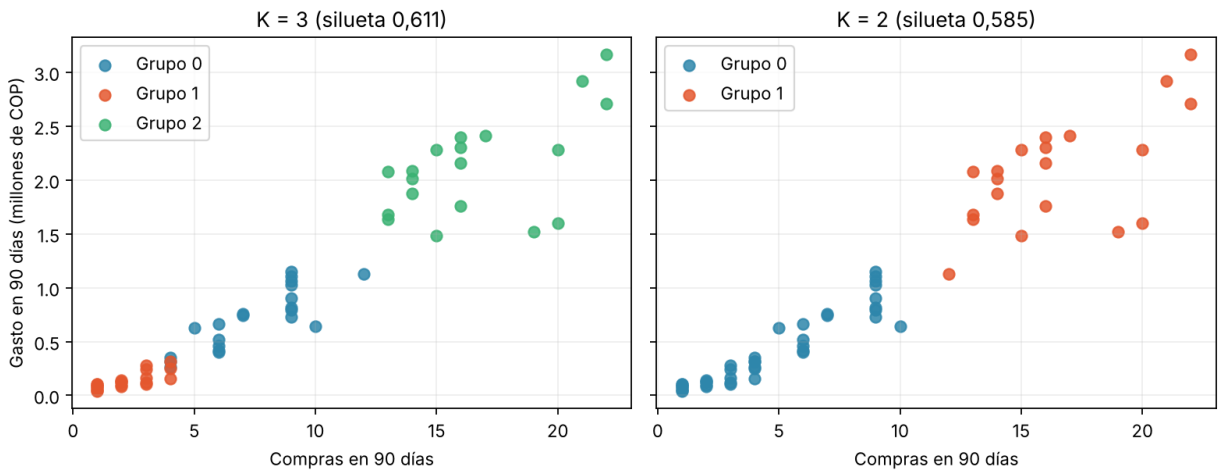


Figura 1. Clientes por compras y gasto en 90 días. Los días desde la última compra también entraron al modelo, pero no se ven en los ejes.

Lectura gerencial: el grupo 2 (19 clientes) compra mucho, gasta alrededor de 2,1 millones y compró hace una semana en promedio; es el grupo a cuidar con beneficios de fidelidad. El grupo 1 (20 clientes) compra poco, gasta cerca de 136.000 pesos y lleva más de dos meses sin volver; es el que está en riesgo y necesita reactivación. El grupo 0 (21 clientes) está en el medio, con compras recientes y gasto moderado, y es el candidato natural para empujar una segunda o tercera compra.

4. Mini reto: K = 3 frente a K = 2

Con K = 2 la silueta baja a 0,585 (frente a 0,611). Los grupos de K = 3 que estaban en los extremos casi no cambian (20 de 21 clientes del grupo 0 y los 20 del grupo 1 de K = 3 quedan juntos; el grupo de alto valor se mantiene con 20 clientes). El cambio importante es que los clientes de recompra y de riesgo se fusionan en un solo grupo de 40, con 4,7 compras, 411.575 pesos y 45,4 días sin comprar. Ese promedio apenas supera el umbral de 45 días, así que la regla lo etiquetaría entero como 'reactivación' y se perdería la diferencia entre clientes en riesgo y clientes recientes. Por eso K = 3 es más útil para decidir campañas aquí.

Evidencia de aprendizaje (tabla del cuaderno)

Evidencia	Respuesta
Silueta con K = 3 y con K = 2	K = 3: 0,611. K = 2: 0,585.
Un cambio observado en los grupos	Con K = 2 se fusionan los grupos de recompra (21) y riesgo (20) en uno de 40 clientes; el grupo de alto valor casi no cambia.
Grupo elegido y dos datos que justifican su campaña	Grupo 1 de K = 3, reactivación: promedia 65,2 días sin comprar y solo 2,2 compras en 90 días.
Mensaje de campaña (máx. 25 palabras)	«Te extrañamos: vuelve esta semana y recibe un 10 % de descuento en tu próxima compra.» (16 palabras)
¿Por qué es aprendizaje no supervisado?	Porque el modelo no recibe una variable objetivo ni etiquetas correctas; encuentra los grupos solo por la similitud entre clientes.

5. Limitaciones y recomendaciones

Los datos son ficticios y diseñados para formar grupos visibles, así que una silueta alta no demuestra que una campaña funcione con clientes reales. El modelo se ajustó a todos los registros porque la práctica es exploratoria; no se evalúa predicción de ventas. Los umbrales de 45 días y 10 compras son supuestos modificables. Recomendaciones: probar las campañas con una muestra pequeña y medir la respuesta; repetir el análisis con datos reales (por ejemplo, los comentarios y videos de YouTube si se quiere dar continuidad al proyecto) y revisar el valor de K también con otras métricas, no solo con la silueta.

Referencias

scikit-learn developers. (s. f.). *KMeans*. https://scikit-learn.org/stable/modules/generated/sklearn.cluster.KMeans.html

scikit-learn developers. (s. f.). *StandardScaler*. https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html

scikit-learn developers. (s. f.). *silhouette_score*. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_score.html

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53-65.