Análisis de comentarios y títulos de YouTube mediante procesamiento de lenguaje natural

Natalia Rios, Maicol Lopez, Daniela Romero

Universidad de Cundinamarca, Extensión Facatativá

Machine learning y algoritmos genéticos

Fredy Martinez

21 de octubre de 2026

Análisis de comentarios y títulos de YouTube mediante procesamiento de lenguaje natural

Este informe interpreta los resultados de dos cuadernos de procesamiento de lenguaje natural (PLN). El Cuaderno 1 clasifica comentarios de YouTube en sentimiento negativo, neutral o positivo mediante TF-IDF y regresión logística. El Cuaderno 2 agrupa títulos de videos con TF-IDF, reducción de dimensiones (LSA) y k-medias (*k-means*) y valora la calidad de la agrupación con el coeficiente de silueta (Rousseeuw, 1987). Ambos se apoyan en la biblioteca scikit-learn (Pedregosa et al., 2011). Las etiquetas de sentimiento siguen la convención de trabajo del cuaderno (0 = negativo, 1 = neutral, 2 = positivo), que no corresponde a una verificación humana independiente.

1. Preparación de los cuadernos

El Cuaderno 1 se ejecutó con el archivo comments.csv y el Cuaderno 2 con videos-stats.csv, ambos sin modificar. Para el Cuaderno 1 se usó la semilla 42 y una única partición entrenamiento-prueba que separa los videos (80 % aproximado de los videos para entrenar y 20 % para evaluar), de modo que ningún video aparece en ambos conjuntos.

2. Calidad de los datos

La Tabla 1 resume la auditoría de ambos cuadernos. En el Cuaderno 1, el problema principal fue la repetición de registros: 148 filas exactamente iguales y, ya para el modelado, 288 textos repetidos y 2 textos idénticos con etiquetas contradictorias. En el Cuaderno 2, 12 filas repetían un video ya registrado (en 9 de esos videos los valores diferían entre registros) y se detectaron conteos negativos (7 en Likes y 2 en Comments), que funcionan como marcador de dato desconocido y no como una cifra real.

Tabla 1

Auditoría de calidad de los datos en ambos cuadernos

Aspecto	Cuaderno 1 (comentarios)	Cuaderno 2 (títulos)
Registros originales	18.409	1.881
Registros después de la limpieza	18.260 (1.869 videos)	1.869 videos únicos (1.859 con métricas completas para calcular proporciones)
Problema de calidad encontrado	148 duplicados exactos, 1 texto vacío, 2 textos idénticos con etiquetas contradictorias y 288 repeticiones de texto	12 filas adicionales de videos ya registrados (9 con valores distintos entre registros), 2 videos sin vistas válidas y conteos negativos (7 en Likes, 2 en Comments)
Tratamiento aplicado	Se retiraron duplicados y el registro vacío; para el modelo se excluyeron los textos contradictorios y se conservó una sola copia de cada texto repetido	Se conservó la primera fila de cada *Video ID*, los negativos se convirtieron en datos faltantes y las palabras clave se guardaron en una tabla aparte
Error posible si no se corrigiera	Fuga de información: el mismo comentario en entrenamiento y prueba inflaría el desempeño; los textos contradictorios confundirían al clasificador	Los videos repetidos se contarían dos veces en totales y agrupaciones; un valor negativo restaría a promedios y generaría proporciones sin sentido

Nota. Elaboración propia a partir de la celda 05 del Cuaderno 1 y la celda 05 del Cuaderno 2.

3. Transformación del lenguaje

La Tabla 2 muestra dos comentarios y dos títulos en su forma original, normalizada y tokenizada. Se usan fragmentos para facilitar la lectura; […] indica texto omitido.

Tabla 2

Ejemplos de normalización y tokenización

Ejemplo	Texto original	Texto normalizado	Tokens
Comentario 1	Whenever I go to a place that doesn’t take Apple Pay (doesn’t happen too often), it’s such a drag. […]	whenever i go to a place that does not take apple pay (does not happen too often), it's such a drag. […]	whenever, i, go, to, a, place, that, does, not, take, apple, pay, does, not, happen, too, often, it's, such, a, drag, […]
Comentario 2	Linus, I'm an engineer and love the LMG content across all the channels. […]	linus, i'm an engineer and love the lmg content across all the channels. […]	linus, i'm, an, engineer, and, love, the, lmg, content, across, all, the, channels, […]
Título 1	Best Tech/EDC Gifts Under $50 for Father's Day! - Gift Guide 2022	best tech/edc gifts under $50 for father's day! - gift guide 2022	best, tech, edc, gifts, under, for, father's, day, gift, guide
Título 2	OnePlus 10R vs 10T | Unboxing & Comparison	oneplus 10r vs 10t | unboxing & comparison	oneplus, vs, unboxing, comparison

Nota. Elaboración propia con las funciones de normalización y tokenización de los cuadernos.

En el Comentario 1, la contracción *doesn’t* se convirtió en *does not*, de modo que la negación quedó como un token independiente (*not*), y el apóstrofo tipográfico se reemplazó por

uno simple. En el Título 1, la entidad HTML *'* se transformó en un apóstrofo; los números (*50*, *2022*) y el símbolo $ no generan tokens, y en el Título 2 desaparecen *10R* y *10T*, un límite que conviene tener presente. El texto debe representarse con números porque los modelos de ambos cuadernos operan sobre matrices: TF-IDF asigna a cada término un peso según su frecuencia en el texto y su rareza en el corpus (Manning et al., 2008), y tanto la regresión logística como k-medias necesitan esos vectores para calcular probabilidades o distancias.

4. Resultados del Cuaderno 1

El modelo TF-IDF con regresión logística obtuvo un F1 macro de 66,1 sobre 100 y una exactitud de 73,6 % en 3.580 comentarios de 370 videos reservados, frente a un F1 macro de 25,5 de la referencia que siempre predice la clase mayoritaria. La clase positiva se reconoce mejor (recall de 79,7 % y precisión de 91,0 %) que la negativa (recall de 63,6 % y precisión de 45,2 %) y la neutral (recall de 63,4 % y precisión de 58,0 %). La Tabla 3 presenta seis comentarios del conjunto de prueba, tres aciertos y tres desacuerdos.

Tabla 3

Comentarios del conjunto de prueba: etiqueta del archivo, predicción e interpretación

N.º	Comentario	Etiqueta del archivo	Predicción	Interpretación del equipo	Justificación
1	I love how he explained the steps of Machine Learning in simplified plain english. thank you very much!!	Positivo	Positivo	Positivo (coincide)	Contiene expresiones claras de agrado (*love*, *thank you very much*), el tipo de léxico que TF-IDF captura bien.
2	5:00 It's usually not a vulture it's a condor or a Andean condor	Neutral	Neutral	Neutral (coincide)	Aunque incluye la negación *not*, es una corrección informativa sin carga emocional; el modelo no confundió negación con sentimiento negativo.
3	It's very rare that something like this would ever happen to a former president in fact this is a first.	Negativo	Negativo	Neutral o ambiguo (etiqueta discutible)	Sin el video no se sabe si el comentarista celebra o lamenta el hecho. Aquí el modelo y la etiqueta coinciden, pero la etiqueta es discutible por falta de contexto.
4	Man Ryan takes forever to get to the point	Negativo	Neutral	Negativo (error del modelo)	La queja está en una expresión (*takes forever*) sin palabras negativas típicas; un modelo de palabras sueltas no la capta.
5	if u listen this with a subwoofer it is absolute fire	Positivo	Negativo	Positivo (error del modelo)	*Fire* es jerga de elogio; el modelo la asocia con un sentido literal o negativo. Es un caso de lenguaje coloquial.
6	They used to *kind of* have a "can I trust this" feature. It was called the dislike count. Not that this ever stopped 5-minute crafts.	Neutral	Negativo	Negativo con ironía (etiqueta discutible)	Es una crítica sarcástica a la plataforma; el modelo la clasifica como negativa y es razonable que lo haga, por lo que la etiqueta neutral es la discutible.

Nota. Elaboración propia a partir de la celda 14 y del archivo de predicciones de prueba del Cuaderno 1.

5. Experimento con el Cuaderno 2: K = 4 frente a K = 6

Se ejecutó el Cuaderno 2 dos veces con el mismo archivo, la misma semilla (42) y los mismos parámetros (TF-IDF con palabras y bigramas, reducción LSA a 50 componentes y k-medias), cambiando solo K_GRUPOS en la celda 02. En ambas se agruparon 1.856 de los 1.869 videos únicos; 13 quedaron fuera porque su título no conservó vocabulario útil. El coeficiente de silueta (distancia coseno, calculado sobre una muestra de 1.000 títulos) mide qué tan separado queda cada título de los otros grupos, con valores de −1 a 1; no es un porcentaje de aciertos (Rousseeuw, 1987). La Tabla 4 resume ambas configuraciones.

Tabla 4

Comparación de las configuraciones de agrupamiento de títulos

Configuración	Silueta	Observaciones al leer los títulos	Ejemplo y justificación
K = 4 (tamaños: 610, 651, 449 y 146)	0,078	Grupo 3 (449 títulos, términos: *science*, *data*, *computer*): *What is Data Science?*, *Modern Physics* || *Modern Physics Full Lecture Course* y *Ex-Trump lawyer defends Trump against NYT report*. Los dos primeros comparten tema educativo y científico; el tercero no. Grupo 4 (146 títulos, términos: *asmr*, *nintendo*, *mukbang*): *ASMR Relaxing Spa Facial Treatment*, *ASMR MUKBANG | 치즈 불닭볶음면 […]* y *Top 10 Must Have Nintendo Switch Games! 2022 Guide*. Los dos primeros son ASMR; el tercero es de videojuegos. Los grupos 1 y 2 (610 y 651 títulos) reúnen palabras clave muy distintas (*trolling*, *history*, *interview*; *literature*, *minecraft*, *music*).	Coherente: *What is Data Science?*, que encaja con el grupo de ciencia y computación. Problemático: *Top 10 Must Have Nintendo Switch Games! 2022 Guide*, porque con K = 4 los videojuegos de Nintendo quedan mezclados con ASMR y mukbang.
K = 6 (tamaños: 95, 176, 478, 381, 245 y 481)	0,107	Grupo 1 (95 títulos, términos: *asmr*, *mukbang*, *eating*): *SEAFOOD MUKBANG | KING CRAB SEAFOOD BOIL MUKBANG […]*, *ASMR LoFi MOUTH SOUNDS With the Apple Mic* y *ASMR | Allergy Test & Skin Treatment Medical Exam*. Los tres comparten tema. Grupo 6 (481 títulos, términos: *science*, *data*, *computer*): *6 Reasons Why Computer Science is the Best Major*, *SAT AUGUST TIPS AND TRICKS! DETAILED SAT GUIDE FOR NEW SAT!* y *Stop Overthinking - Lofi hip hop mix ~ Stress Relief, Relaxing Music*. Los dos primeros son de educación y carrera; el tercero es música. Los videos de Nintendo pasaron al grupo 3, junto con reacciones, cripto y Marvel, y los grupos 3 y 4 (478 y 381 títulos) siguen siendo heterogéneos.	Coherente: el grupo 1 de ASMR y mukbang, ahora separado de Nintendo. Problemático: *Stop Overthinking - Lofi hip hop mix […]* dentro del grupo de ciencia y educación, que no comparte tema con los demás títulos.

Nota. Elaboración propia a partir de la celda 12 del Cuaderno 2. Los números de grupo no identifican temas fijos entre ejecuciones; los nombres temáticos son interpretación del equipo.

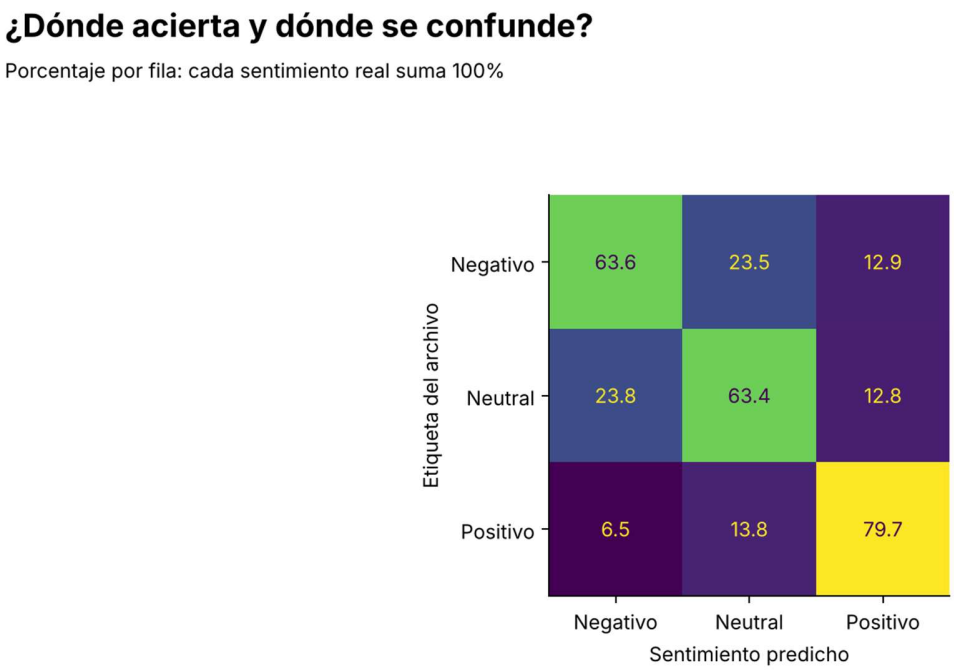
Conclusión del experimento

La configuración con K = 6 resulta más útil para describir los títulos. Su silueta (0,107) es mayor que la de K = 4 (0,078) y, al leer los títulos, produce un grupo de ASMR y mukbang más puro porque separa los videos de Nintendo, que con K = 4 aparecían mezclados con ellos. Aun así, ambas siluetas están cerca de cero, lo que indica solapamiento entre grupos, y con K = 6 persisten dos grupos grandes y heterogéneos (478 y 381 títulos). Por eso los grupos sirven como exploración y no como una clasificación temática definitiva.

6. Interpretación de dos gráficos gerenciales

Figura 1

Coincidencia entre la etiqueta del archivo y la predicción del modelo

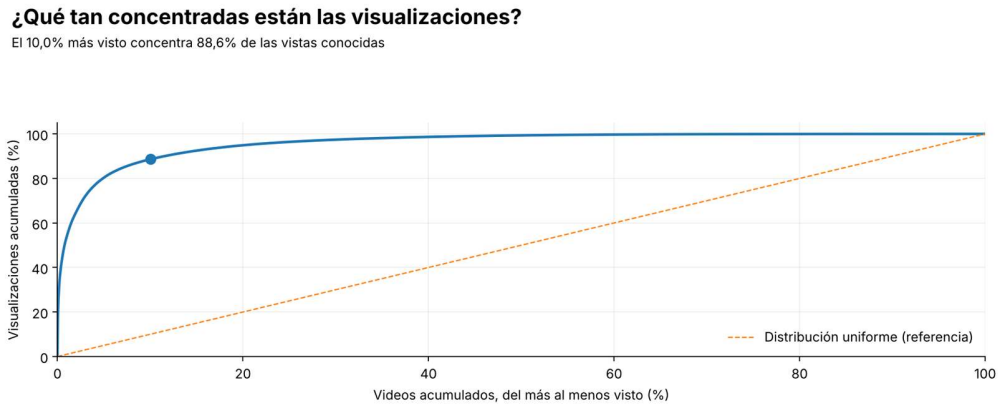


Nota. Cuaderno 1, celda 13. Cada fila suma 100 %; la diagonal indica coincidencia con la etiqueta del archivo.

La Figura 1 compara la etiqueta del archivo con la predicción del modelo para cada sentimiento. Muestra que el modelo coincide con el 79,7 % de los comentarios positivos, pero solo con el 63,6 % de los negativos y el 63,4 % de los neutrales, y que la precisión de la clase negativa es de 45,2 %. No permite concluir que el modelo conozca la opinión real de la audiencia, porque las etiquetas no fueron verificadas por personas y la evaluación usa una sola partición; tampoco permite saber qué parte de los desacuerdos es error del modelo y qué parte, etiqueta discutible.

Figura 2

Concentración de las visualizaciones en los videos más vistos



Nota. Cuaderno 2, celda 10. La línea punteada es la referencia de una distribución uniforme.

La Figura 2 compara la curva acumulada de visualizaciones con una distribución uniforme. Muestra que el 10 % de los videos más vistos (187 de 1.869) concentra el 88,6 % de las visualizaciones conocidas, mientras que la mediana es de 589.907 vistas y el promedio de 11.653.890. No permite concluir cómo evolucionó el alcance en el tiempo, porque no se conoce la fecha de captura, ni que los videos más vistos lo sean por su título: no se controla la antigüedad, el canal ni la audiencia.

7. Conclusiones y recomendación

Conclusión sobre los comentarios

Los comentarios etiquetados son mayoritariamente positivos (62,0 % de 18.260), y el modelo los distingue de forma útil, con un F1 macro de 66,1 frente a 25,5 de la referencia. Su punto débil son los matices: *Man Ryan takes forever to get to the point* (queja implícita) y *if u listen this with a subwoofer it is absolute fire* (jerga) fueron mal clasificados, y la precisión de la clase negativa es de solo 45,2 %.

Conclusión sobre los títulos

Los títulos forman grupos solo parcialmente diferenciados: con K = 6 la silueta es de 0,107 y los grupos más claros giran en torno a ASMR y mukbang (95 títulos) o a ciencia, datos y computación, mientras que otros dos grupos (478 y 381 títulos) mezclan temas. Además, el alcance está muy concentrado: el 10 % de los videos suma el 88,6 % de las vistas, y la longitud del título muestra una correlación de Spearman de −0,279 con las vistas, una asociación moderada que no prueba que acortar un título aumente las visualizaciones.

Recomendación de mejora

Se propone ampliar la lista de palabras vacías con términos de dominio que no describen el tema (*video*, *official*, *best*) y probar representaciones que consideren el significado y varios idiomas, como incrustaciones (*embeddings*) multilingües, ya que muchos títulos y comentarios no están en inglés (por ejemplo, títulos en coreano o tailandés). Para los comentarios, se sumaría el tratamiento de emojis y jerga. La utilidad se comprobaría sin tocar el conjunto de prueba: en el Cuaderno 1, con validación cruzada por video solo dentro del entrenamiento, y en el Cuaderno 2, comparando la silueta y la revisión manual a ciegas de 20 títulos por grupo por dos personas, midiendo cuántos comparten tema. No se afirmaría que una característica del título cause más visualizaciones a partir de las asociaciones observadas.

Anexo A. Cruce entre sentimiento de los comentarios y métricas de los videos

Al unir ambos archivos por *Video ID* se obtuvieron 1.826 videos con al menos cinco comentarios. La Tabla A1 muestra que los videos con menos likes por vista tienen la mayor proporción de comentarios negativos (17,0 %), mientras que la relación general es débil.

Tabla A1

Distribución media del sentimiento según la tasa de likes por vista (cuartiles)

Cuartil de likes por vista	Positivo (%)	Neutral (%)	Negativo (%)
Q1 (menos likes por vista)	57,2	25,8	17,0
Q2	63,9	23,5	12,6
Q3	66,0	23,7	10,3
Q4 (más likes por vista)	60,8	27,9	11,4

Nota. Elaboración propia con Cuaderno 1 y videos-stats.csv; 457, 456, 456 y 457 videos por cuartil. Los videos con más comentarios por vista tienen más comentarios negativos (correlación de Spearman = 0,22) y menos positivos (−0,20); la tasa de likes casi no se relaciona con el sentimiento (0,04). Es una asociación, no una relación causal.

Referencias

Jurafsky, D., & Martin, J. H. (2024). *Speech and language processing* (3.ª ed., borrador). https://web.stanford.edu/~jurafsky/slp3/

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825–2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53–65. https://www.sciencedirect.com/science/article/pii/0377042787901257?via%3Dihub&__cf_chl_rt_tk=6e60AAePdnXy03n0di7ws1Qubq39843oRaVxvhK8DBI-1792633359-1.0.1.1-0skhYJFOtSGcXbIfe1qH.qPfii4Y0.BEVExI7mpMWeI