Proyecto estadísticas de YouTube - Avances III
Resultados, evaluación frente al diseño inicial y lecciones aprendidas

[COMPLETAR: máximo 3 integrantes]
Universidad de Cundinamarca, Extensión Facatativá
Machine learning y algoritmos genéticos / Procesamiento de lenguaje natural
Docente: Fredy Martinez
Semana 10 - Noviembre de 2026

Repositorio de GitHub: [COMPLETAR: https://github.com/...]
Cuadernos en Google Colab: [COMPLETAR: enlaces a los cuadernos]

1. Resumen del proyecto

El proyecto analizó dos archivos de YouTube, comments.csv (comentarios) y videosstats.csv (estadísticas de videos), con técnicas de procesamiento de lenguaje natural en Google Colab. Se trabajó en tres frentes: (1) un clasificador de sentimiento de comentarios con TF-IDF y regresión logística; (2) el agrupamiento de títulos con TF-IDF, LSA y k-medias; y (3) el cruce de ambos archivos por Video ID para relacionar sentimiento y visualizaciones. Este informe evalúa los resultados frente al diseño inicial, describe los retos y sus soluciones, y recoge las lecciones aprendidas. Todas las conclusiones son asociaciones descriptivas de esta muestra, no relaciones causales.

2. Resultados frente al diseño inicial

Objetivo	Resultado obtenido	Evaluación
Clasificar el sentimiento de los comentarios	F1 macro de 66,1 y exactitud de 73,5 % en 3.580 comentarios de 370 videos reservados	Supera la referencia de clase mayoritaria (F1 macro de 25,5). La clase negativa es la más débil (precisión de 45,2 %).
Agrupar los títulos por tema	K = 6: silueta de 0,107 (K = 4: 0,078); 1.856 de 1.869 videos agrupados	Grupos claros de ASMR y mukbang, y de ciencia y computación; dos grupos grandes (478 y 381) siguen mezclados.
Relacionar sentimiento y alcance	Spearman rho = 0,143; grupo Alto 65,8 % positivo frente a 55,7 % del Bajo (+10,10 puntos); 1.834 videos	Asociación positiva y débil; no es causal.
Explorar el vocabulario con TF-IDF	'not' lidera los filtros negativos, pero también aparece en comentarios positivos	El peso TF-IDF describe frecuencia, no sentimiento.
Describir el alcance	El 10 % de los videos más vistos concentra el 88,6 % de las vistas	Distribución muy concentrada.

Tabla 1. Resultados y evaluación.

Logros: todos los hallazgos se sustentaron con cifras y ejemplos y se evitó afirmar causalidad. **Brechas:** el desempeño por clase es desigual, la silueta de los títulos quedó cerca de cero y las etiquetas de sentimiento no fueron verificadas por personas. [COMPLETAR: si el diseño inicial fijaba metas numéricas, comparen aquí cada una con el resultado.]

3. Retos del proyecto y cómo se solucionaron

Reto	Solución	Resultado
Duplicados en comentarios: 148 exactos, 1 texto vacío, 288 textos repetidos y 2 idénticos con etiquetas contradictorias	Se retiraron duplicados y el registro vacío; para el modelo se excluyeron los contradictorios y se dejó una copia de cada texto repetido	18.260 comentarios válidos y sin el mismo texto en entrenamiento y prueba

Reto	Solución	Resultado
Videos repetidos: 1.881 filas para 1.869 videos, con valores distintos entre registros	Se conservó la primera fila de cada Video ID	Sin totales inflados, aunque no se sabe cuál captura es la más reciente
Conteos negativos (7 en Likes y 2 en Comments)	Se convirtieron en datos faltantes	Proporciones coherentes para 1.859 videos
Fuga de información entre entrenamiento y prueba	Partición única por video (80 %/20 %, semilla 42)	Evaluación más honesta
Negaciones, jerga e ironía	Se expandieron contracciones y se conservaron no, not, nor y never	Se conserva la negación; jerga e ironía siguen fallando
Videos con pocos comentarios	MIN_COMENTARIOS = 5	35 videos y 97 comentarios fuera; porcentajes más estables
Elegir el número de grupos	Experimento K = 4 frente a K = 6 con misma semilla y parámetros	Se eligió K = 6
Etiquetas que apuntan a otro objeto (p. ej. una queja contra Amazon en un video de John Oliver)	Revisión manual de ejemplos de contexto	Se concluyó que la etiqueta no equivale a opinión sobre el video

Tabla 2. Retos y soluciones.

4. ¿Cuánto cambió la solución final respecto al diseño inicial?

Aspecto	Diseño inicial	Solución final	Magnitud del cambio
Número de grupos de títulos	K = 4 (silueta 0,078)	K = 6 (silueta 0,107)	Silueta +37 %; Nintendo se separa de ASMR y mukbang
Partición de datos	[COMPLETAR]	Por video, 80 %/20 %	Evita fuga de información
Unidad de análisis del sentimiento	[COMPLETAR]	Por video, con mínimo de 5 comentarios y mismo peso por video	35 videos excluidos
Grupos de alcance	[COMPLETAR]	Terciles de vistas (Bajo, Medio, Alto)	Grupos relativos a la muestra
Métricas del cruce	[COMPLETAR]	Se añadieron likes por vista y comentarios por vista (Anexo A del informe anterior)	Los videos con más comentarios por vista tienen más negativos (rho = 0,22)

Tabla 3. Cambios del diseño. Las celdas [COMPLETAR] dependen de su diseño inicial, que no conozco.

En resumen, el núcleo del diseño (TF-IDF, regresión logística, LSA y k-medias) se mantuvo y los cambios fueron de método y de control de calidad, no de enfoque. [COMPLETAR: una frase propia sobre cuánto se parece el resultado a lo planeado.]

5. Mejoras implementadas y su efecto

Las mejoras propuestas en el informe anterior se implementaron en un cuaderno nuevo (04_PLN_Mejoras.ipynb). Las variantes se eligieron solo con validación cruzada por video dentro del entrenamiento (3 particiones) y la prueba se usó una única vez.

Cambio	F1 macro en validación cruzada	Resultado
Original: palabras y bigramas	0,6675	Punto de partida
+ emojis convertidos en tokens (positivo, negativo, otro)	0,6709	Mejora pequeña (+0,003), dentro del ruido (desv. de 0,006 a 0,007)
+ emojis + n-gramas de caracteres (2 a 5)	0,6978	Mejora de +0,030; elegida
Mismo con C = 0,5 / 1 / 2 / 4	0,6895 / 0,6978 / 0,6996 / 0,7010	Se eligió C = 4 (diferencias entre valores pequeñas)

Tabla 4. Selección de la mejora de comentarios con validación cruzada por video.

Modelo en la prueba (3.580 comentarios, 370 videos)	Exactitud	F1 macro	F1 negativo	F1 neutral	F1 positivo
Original	73,6 %	66,1	52,6	60,5	85,1
Mejorado (emojis + caracteres, C = 4)	78,3 %	70,4	57,0	65,8	88,3

Tabla 5. Resultado final en la prueba. Diferencia de F1 macro: +4,4 puntos, con intervalo de confianza del 95 % por bootstrap de videos de [3,1; 5,7] puntos, que no incluye el cero. El recall de la clase negativa bajó de 63,6 % a 59,1 % mientras subió su F1; la mejora no es uniforme.

Títulos. Se probó una lista de palabras vacías de dominio (video, official, best, new, vs, etc.). La silueta con K = 6 fue 0,103 frente a 0,107 sin ella, y con cinco semillas dio 0,108 (desv. 0,003) frente a 0,107 (desv. 0,002): no hay mejora real. Además, la silueta sube al aumentar K (0,069 con K = 4 hasta 0,168 con K = 10), por lo que no basta para elegir K. Los embeddings multilingües no se probaron porque requieren descargar un modelo externo; quedan como trabajo futuro.

6. Lecciones aprendidas

Técnicas. Auditar y limpiar antes de modelar cambió los resultados; separar por video evita fugas; una silueta cercana a cero advierte solapamiento; un peso TF-IDF alto describe frecuencia y no sentimiento; y una correlación débil (rho = 0,143) obliga a hablar de asociación y no de causa.

De proceso. Cambiar un solo parámetro por experimento permite comparar con justicia; revisar ejemplos concretos complementa las métricas; y el código es un medio, mientras que lo importante es la arquitectura del análisis y las conclusiones que se pueden sostener. **Mejoras futuras:** probar embeddings multilingües, revisar a ciegas una muestra de títulos por grupo y verificar manualmente las etiquetas de sentimiento. Las mejoras de emojis y caracteres ya se implementaron (sección 5). Lección adicional: una mejora solo cuenta si supera la variación entre semillas o particiones; las palabras vacías de dominio no la superaron.

7. Trabajo colaborativo

[COMPLETAR con datos reales: reparto de tareas, commits o pull requests en GitHub, reuniones y revisiones cruzadas.]

Integrante	Aportes principales	Evidencia
[Nombre 1]	[COMPLETAR]	[commits / capturas]
[Nombre 2]	[COMPLETAR]	[commits / capturas]
[Nombre 3]	[COMPLETAR]	[commits / capturas]

Tabla 6. Distribución del trabajo (máximo 3 estudiantes).

8. Herramientas

Google Colab para ejecutar los cuadernos, GitHub para versionar y entregar el código, pandas para limpieza y cruces, scikit-learn para TF-IDF, regresión logística, LSA, k-medias y silueta, y SciPy para la correlación de Spearman.

Referencias

Manning, C. D., Raghavan, P., & Schütze, H. (2008). *Introduction to information retrieval*. Cambridge University Press.

Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research, 12*, 2825-2830.

Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics, 20*, 53-65.

SciPy community. (s. f.). *scipy.stats.spearmanr*. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.spearmanr.html