TALLER DE SENTIMIENTOS Y ALCANCE EN YOUTUBE

Natalia Rios, Maicol Lopez y Daniela Romero

Objetivo

Relacionar las etiquetas de sentimiento de los comentarios con las visualizaciones de los videos y explorar su vocabulario mediante TF-IDF. Sustentar los hallazgos con cifras y ejemplos, sin afirmar causalidad.

Material cuaderno PLN_Sentimientos_y_Alcance.ipynb y archivos comments.csv y videos-stats.csv. Trabajo individual o en parejas.

En esta práctica, alcance significa visualizaciones registradas, no personas únicas. Se usan etiquetas existentes; no se entrena un nuevo clasificador.

1. Cargar los archivos (celda 01)

Abra el cuaderno en Google Colab, escriba su nombre y grupo y ejecute la celda. Cargue los dos CSV con sus nombres originales. Continúe en orden; no necesita ejecutar los cuadernos anteriores.

2. Revisar la calidad de los datos (celda 02)

Observe la auditoría y registre estos resultados. Explique un riesgo de contar varias veces el mismo video.

Control	**Resultado**
Comentarios originales / comentarios válidos	**18.409 / 18.260 (148 duplicados exactos y 1 registro no válido excluidos)**
Duplicados exactos de comentarios retirados	**148**

Control	Resultado
Videos únicos	**1.869 (de 1.881 filas originales de videos)**

Riesgo identificado: Si un mismo Video ID aparece en varias filas y se cuentan todas, sus visualizaciones se repiten: se inflan los totales y ese video recibe un peso desproporcionado en los terciles de alcance, los promedios por grupo y la correlación de Spearman. En los datos, 4 videos tienen título o vistas distintos entre filas repetidas; conservar solo la primera fila evita duplicarlos, pero no permite saber cuál captura es la más reciente (pandas development team, s. f.).

3. Relacionar sentimientos y visualizaciones (celda 03)

Mantenga MIN_COMENTARIOS = 5. Identifique cuántos videos entran al análisis y cómo se forman los grupos Bajo, Medio y Alto. Los grupos son relativos a esta muestra; no son categorías oficiales.

Videos analizados **1.834** Comentarios asociados **18.163**
Porcentaje positivo = comentarios positivos / comentarios válidos del video × 100. Con MIN_COMENTARIOS = 5 quedan fuera 35 videos y 97 comentarios. Grupos por terciles de vistas de la muestra: Bajo (hasta -186.568; 612 videos), Medio (hasta 1.633.059; 611) y Alto (más de -1.633.059; 611).

4. Interpretar los gráficos (celdas 04 y 05)

Registre el coeficiente de Spearman y la diferencia entre los grupos Alto y Bajo. Observe que el primer gráfico usa escala logarítmica y que el segundo da el mismo peso a cada video.

Spearman (rho) ,143 Diferencia Alto − Bajo +10,10 puntos porcentuales (65,8 % frente a 55,7 %).
¿Qué puede concluir sin afirmar una causa? Existe una asociación monotónica positiva y débil (ρ = ,143) entre las visualizaciones y el porcentaje de comentarios positivos por video (SciPy community, s. f.). Los videos de alcance Alto tienen en promedio 10,10 puntos porcentuales más de comentarios positivos que los de alcance Bajo, y la diferencia se concentra entre Bajo y los otros grupos (Medio: 64,3 %). Es una descripción de esta muestra, no una causa: se desconoce cómo se seleccionaron los comentarios, las vistas no son personas únicas y no se controlaron variables como tema, antigüedad del video o moderación.

5. Observar la transformación del lenguaje (celda 06)

Seleccione un comentario de los ejemplos y compare su versión original, el texto normalizado y los tokens. Indique dos cambios y verifique si conserva la negación.

Cambio 1 Normalización: el texto pasa a minúsculas y las contracciones negativas se expanden ("don't" → "do not").
Cambio 2 Tokenización y filtro de palabras vacías: "pay-wave" se separa en "pay" y "wave", y se eliminan palabras vacías del inglés (here, in, of, the) pero se conservan no, not, nor y never. La negación se conserva: "not" aparece dos veces en los tokens finales.
Explique en una frase qué representa una fila y una columna de la matriz TF-IDF. Su peso no es una puntuación de sentimiento.
Cada fila es un comentario (18.163) y cada columna un término del vocabulario (4.000); el valor es el peso del término en ese comentario según su presencia y qué tan poco frecuente es en el conjunto (scikit-learn developers, s. f.), sin medir polaridad.

6. Experimentar con los filtros (celda 07)

Cambie SENTIMIENTO y ALCANCE según la tabla. Ejecute solamente la celda 07 después de cada cambio; conserve iguales los otros parámetros. Registre el tamaño del subconjunto y sus dos primeros términos.

Sentimiento	**Alcance**	**Comentarios**	**Dos primeros términos**
Negativo	Alto	**647**	**not, like**
Positivo	Alto	**4.010**	**love, not**
Negativo	Bajo	**796**	**not, people**

¿Qué cambió en el vocabulario? En Positivo/Alto aparecen términos de valoración y agradecimiento (love, thank, good, great, video, song), aunque "not" sigue en segundo lugar (674 comentarios; p. ej., "not gonna lie", "not bad"), por lo que la negación no es exclusiva de lo negativo. En los dos filtros negativos "not" encabeza la lista, con like, just, never y no; "people" destaca más en Bajo (2.º lugar) que en Alto (6.º). Un peso TF-IDF alto describe frecuencia relativa en el subconjunto y no define el sentimiento.
Estos filtros cambian el análisis de vocabulario, no la correlación ni los gráficos globales. El historial de experimentos se conserva durante la sesión.

7. Revisar el contexto de dos comentarios

Tome un comentario de Negativo/Alto y otro de Positivo/Alto. En cada caso, anote una frase breve como evidencia y explique a qué se dirige la opinión al video, a un producto o a otro objeto.

Caso	**Evidencia del texto y objeto de la opinión**
Negativo / Alto	**Video "Tech Monopolies: Last Week Tonight with John Oliver". Evidencia: "my Amazon account was closed with no warning". Objeto: Amazon (empresa y servicio); la queja no se dirige al video ni al presentador.**
Positivo / Alto	**Video "The most EXPENSIVE thing I own". Evidencia: "I love the direction this channel is going". Objeto: el canal y la evolución de su contenido.**

¿La etiqueta le parece adecuada en ambos casos? Positivo/Alto: adecuada, coincide con el texto ("I love…"). Negativo/Alto: refleja el tono de queja, pero es engañosa si se lee como insatisfacción con el video, pues el usuario relata una mala experiencia con Amazon. Duda adicional: otro comentario del mismo filtro, que cuenta con entusiasmo cómo el episodio lo inspiró a hacer una tesis, también quedó como Negativo; se desconoce el motivo y las etiquetas no se verificaron manualmente, por lo que requiere revisión humana.

8. Concluir y entregar (celda 08)

Defina técnicamente las conclusiones y recomendaciones con una cifra, los **hallazgos_pln** con un ejemplo y LIMITACION con algo que los datos no permiten asegurar.

CONCLUSION: Hay una asociación débil y positiva entre vistas y sentimiento (rho = 0,143). En promedio por video, el grupo Alto supera al Bajo en 10,10 puntos porcentuales (65,8 % vs. 55,7 %); es una asociación descriptiva, no causal.

HALLAZGO_PLN: El término "not" encabezó Negativo/Alto, pero también aparece en Positivo/Alto (p. ej., "not gonna lie", "not bad"). En un comentario negativo, "not" criticaba a Amazon, no al video: el peso TF-IDF no indica sentimiento ni objeto.

LIMITACION: No se puede asegurar que más vistas causen más comentarios positivos ni generalizar a toda la audiencia: la muestra es de selección desconocida, las vistas no son personas únicas, los grupos son relativos y las etiquetas no se verificaron manualmente.

Referencias

pandas development team. (s. f.). *pandas.DataFrame.merge*. https://pandas.pydata.org/docs/reference/api/pandas.DataFrame.merge.html

scikit-learn developers. (s. f.). *TfidfVectorizer*. https://scikit-learn.org/stable/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html

SciPy community. (s. f.). *scipy.stats.spearmanr*. https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats.spearmanr.html