Lenguaje y sentimientos en comentarios

Estudiante: Por completar | Grupo: Por completar
Análisis: 2026-11-09 16:44 -05

18.260	1.869	66,1
Comentarios depurados	Videos representados	F1 macro / 100

Resumen para la toma de decisiones

Se conservaron 18.260 de 18.409 registros; 148 duplicados exactos se retiraron.

La etiqueta más frecuente es Positivo: 62,0% del corpus depurado. No equivale a la opinión de toda la audiencia.

La mediana de extensión es 21 palabras por comentario.

F1 macro del modelo: 66,1 sobre 100; referencia: 25,5. Diferencia: 40,6 puntos.

Control de calidad

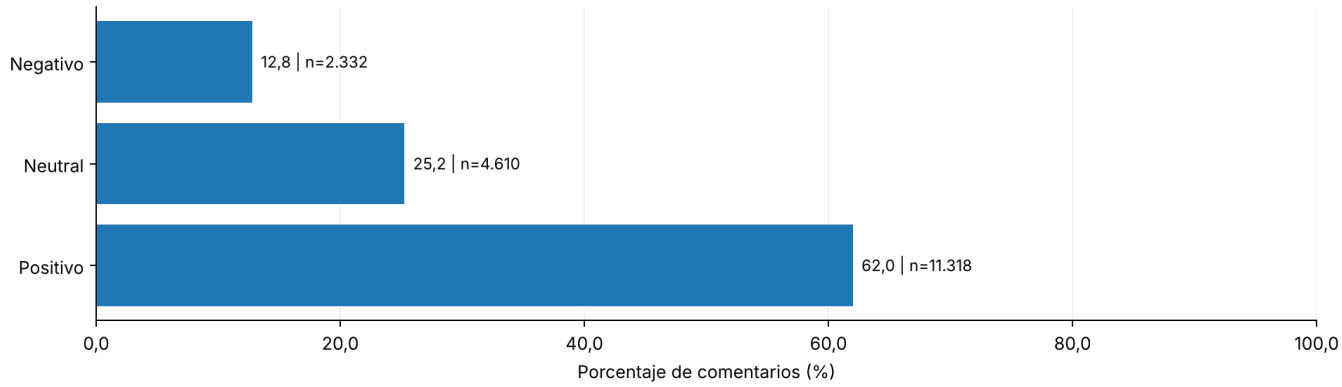
Control	Cantidad
Registros originales	18409
Duplicados exactos retirados	148
Registros rechazados después de deduplicar	1
Likes negativos convertidos en vacío	0
Comentarios conservados	18260
Videos representados	1869

Fuente: comments.csv suministrado para la clase. No se conoce el método de muestreo ni el procedimiento de etiquetado. Convención revisable: 0 negativo, 1 neutral y 2 positivo.

01 / Perfil del corpus

¿Cómo se distribuyen las etiquetas?

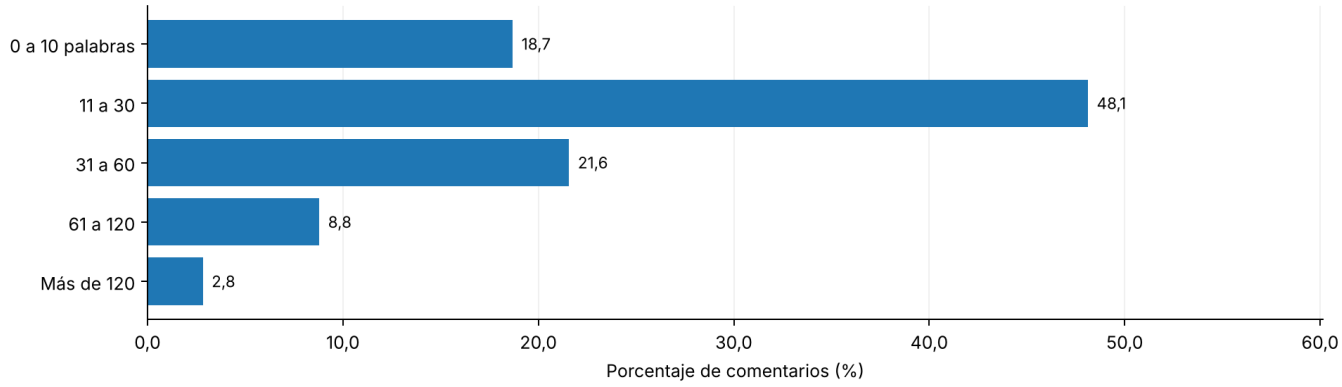
Base depurada: 18.260 comentarios | Convención 0/1/2 revisable



Las barras resumen etiquetas ya existentes. No se infiere satisfacción de toda la audiencia ni se identifican personas.

¿Qué tan extensos son los comentarios?

Mediana: 21 palabras | Se incluyen todos los registros conservados

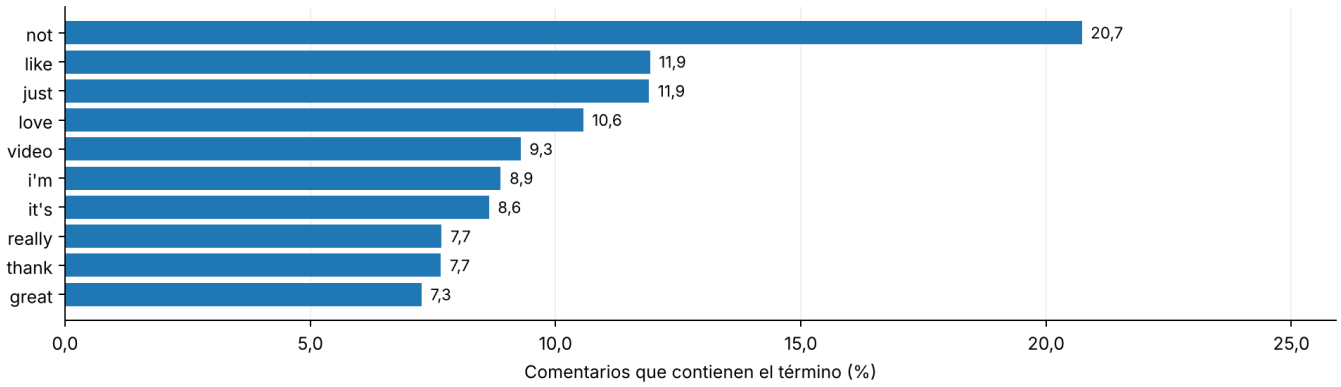


Los intervalos incluyen todos los comentarios depurados. La mediana describe el centro sin quedar dominada por textos extremadamente largos.

02 / Evidencia lingüística

Palabras presentes en más comentarios

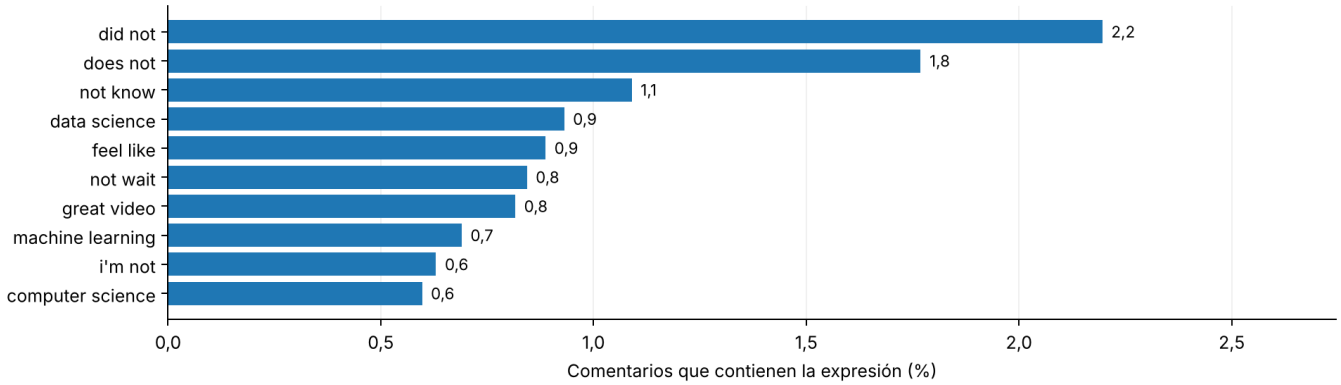
Frecuencia documental; sin palabras vacías inglesas/españolas | No mide importancia causal



Frecuencia documental: un término cuenta una vez por comentario. Una palabra frecuente no es automáticamente la más importante para predecir.

Expresiones de dos palabras más extendidas

Pares adyacentes de palabras de contenido; se preservan negaciones

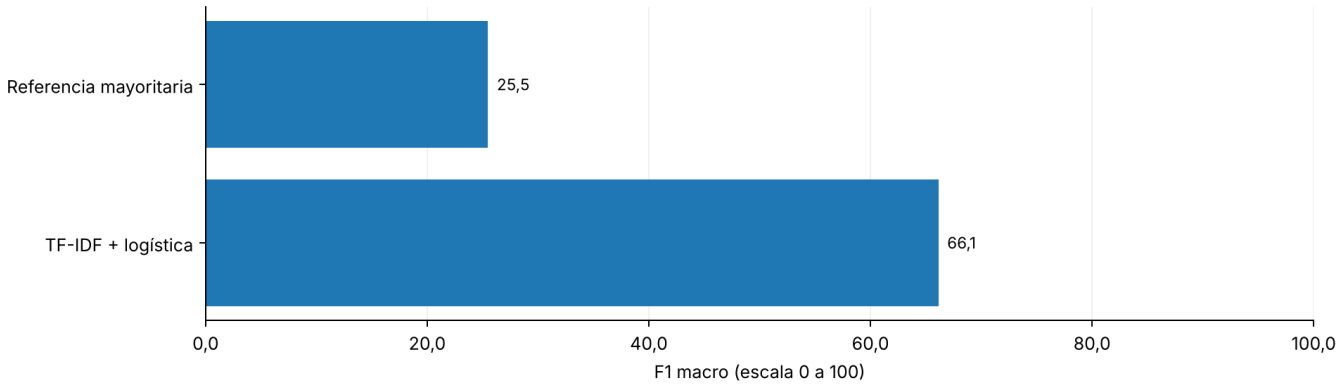


Los bigramas se forman antes de filtrar palabras vacías, manteniendo la adyacencia original. Las listas de inglés y español no cubren todos los idiomas.

03 / Desempeño del clasificador

¿El modelo supera la referencia?

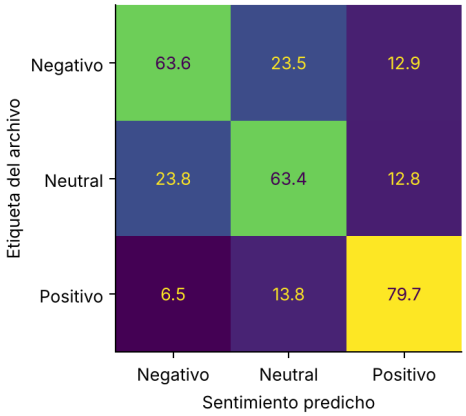
F1 macro en 3.580 comentarios de videos reservados | Más alto es mejor



Prueba con 3.580 comentarios y 370 videos no usados para entrenar. TF-IDF se ajustó solo con entrenamiento.

¿Dónde acierta y dónde se confunde?

Porcentaje por fila: cada sentimiento real suma 100%



La diagonal representa coincidencias con la etiqueta del archivo. Cada fila suma 100%; el soporte de cada clase se presenta en la página siguiente.

04 / Validación, límites y acciones

Desempeño por clase

Clase	Precisión (%)	Recall (%)	F1 / 100	Casos
Negativo	45,2	63,6	52,8	464
Neutral	58,0	63,4	60,6	900
Positivo	91,0	79,7	85,0	2.216

La clase con menor recall es Neutral (63,4%). Conviene revisar sus errores y la calidad de las etiquetas.

Base de modelado: 17.923 textos. Se apartaron 2 registros con texto idéntico y etiquetas contradictorias, además de 288 repeticiones de texto. Estas exclusiones no alteran las estadísticas del corpus depurado.

Alcance de la evaluación

Se utilizó una única partición fija por video, no validación cruzada completa. Los resultados no tienen un intervalo de confianza calculado ni prueban generalización a toda la plataforma. Las etiquetas del CSV pueden contener errores.

Acciones recomendadas

Revisar manualmente errores de la clase con menor recall y comentarios con sarcasmo o negación. Confirmar el diccionario de etiquetas. Para comparar modelos, usar validación por grupos solo dentro del entrenamiento y reservar la prueba final.

Decisiones de procesamiento

Se conservó el texto original. El modelo usa palabras y bigramas, signos ! y ?, y no elimina negaciones. No representa emojis ni contexto audiovisual. La lematización se limita a una demostración opcional de inglés.

WordNet no disponible; se continuó sin lematización.

05 / Interpretación y trazabilidad

¿Qué cambia al limpiar el archivo?

Por completar.

¿Qué palabra o expresión le llamó la atención y por qué?

Por completar.

¿Por qué no basta con mirar accuracy?

Por completar.

¿Qué error del modelo revisó y cómo lo explica?

Por completar.

¿Qué mejora propondría y cómo la validaría sin usar la prueba?

Por completar.

Documentación técnica

scikit-learn: extracción de características, TfidfVectorizer, StratifiedGroupKFold y prevención de fuga de información.
https://scikit-learn.org/stable/modules/feature_extraction.html
https://scikit-learn.org/stable/common_pitfalls.html
https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.StratifiedGroupKFold.html

NLTK: WordNetLemmatizer. https://www.nltk.org/api/nltk.stem.wordnet.html
ReportLab: Platypus. https://docs.reportlab.com/reportlab/userguide/ch5_platypus/

Los CSV de salida contienen los datos depurados, consultas, exclusiones, predicciones y métricas. metadatos.json registra parámetros, versiones y la huella SHA-256 del archivo original.